

Pipeline de detección y backtesting de arbitrajes de opciones

Grupo 3 — Sector Defensa (ETF de referencia: ITA)
Parte 1: Tiempo Discreto — Binomial Pricing & Arbitrage

Agustín Herrera Octavio Lacunza Carolina Grunewald
Delfina González Tiziana Brisighelli

Matemática Aplicada a Problemas Financieros — Universidad de San Andrés
Profesores: Gabriel A. Basaluzzo, Federico M. Glancszpigel, Fernando Kricun

14 de septiembre de 2026

Nota al pie: Todos los resultados de calibración, detección y backtest de este informe se calcularon sobre **velas diarias reales**, descargadas de Polygon, para RTX, BA y LMT entre el 2 de marzo y el 11 de septiembre de 2026. No usamos datos inventados ni simulados en ningún resultado reportado: todo lo que se muestra sale de historia real de mercado.

Índice

1. Resumen ejecutivo	2
2. Objetivo y pregunta financiera	2
3. Activos subyacentes	2
4. Revisión de literatura	3
5. Arquitectura del pipeline	3
6. Obtención de datos	4
6.1. Limitación estructural de Alpaca	4
6.2. Fuente de la evidencia empírica: Polygon (modo diario)	4
7. Limpieza, alineación y control de calidad	5
8. Modelo binomial CRR y calibración de la volatilidad implícita	5
9. Detección de arbitrajes	5
10. Filtros de liquidez	6
11. Backtest: metodología y costos	6
11.1. Resultados con datos reales	6
12. In-sample / out-of-sample y significancia estadística	8
13. Ejecución: paper trading	8
14. Monitoreo y stop-loss	9

15.Resultados finales y conclusiones	9
16.Limitaciones	9
17.Estado consolidado	10
Referencias	10

1. Resumen ejecutivo

Este proyecto construye un proceso reproducible para estudiar posibles arbitrajes de opciones sobre **RTX**, **BA** y **LMT**, constituyentes individuales del ETF ITA. El flujo parte de contratos y cotizaciones, limpia y alinea la información con controles contra *lookahead bias*, calcula volatilidad implícita con un árbol binomial americano (Cox-Ross-Rubinstein), filtra contratos poco operables, detecta inconsistencias frente a las relaciones de no arbitraje y simula la ejecución con costos, latencia y reglas de riesgo.

Datos, limpieza, valuación, detección, backtesting y evaluación ya están implementados y cuentan con **102 tests automatizados**, que corren sin red ni credenciales (verificado el 14-09-2026). La evidencia empírica sale de **365 contratos** y **7.323 velas diarias** reales de RTX, BA y LMT, obtenidas de Polygon (02-mar al 11-sep-2026): son datos históricos reales, día por día, no generados artificialmente.

Sobre esos datos corrimos una grilla factorial de **16 configuraciones** (fuente de precio, spread supuesto, latencia de ejecución, umbral del kill-switch). La señal se detecta al cierre y la orden se ejecuta a la apertura de la rueda siguiente, sólo si el edge recalculado sigue existiendo. En la configuración base (cierre, spread 2%, apertura $t+1$, kill-switch USD 2.000) obtuvimos 92 operaciones, P&L simulado de USD 19.055, hit rate de 97,8%, y el 100% de las 81 operaciones liquidadas al vencimiento cerró con ganancia.

El hallazgo central es que, si bien las **16 configuraciones dan P&L positivo, ninguna alcanza un Sharpe deflactado (DSR) de 0,95**: el resultado todavía no se distingue de lo que produciría una búsqueda de hiperparámetros sobre ruido. Además, el bid/ask es sintético (no hay NBBO histórico gratuito), los cierres entre contratos no son sincrónicos, y el backtest no cobra fondeo ni dividendos discretos en la paridad put-call: el P&L ajustado estimado de la base baja a USD 17.243. La ejecución en paper trading está todavía en fase de piloto y el monitoreo productivo continuo todavía no está desplegado.

2. Objetivo y pregunta financiera

La pregunta que nos hacemos es si la cadena de opciones de RTX, BA y LMT contiene precios incompatibles con las relaciones de no arbitraje para opciones americanas, y si esas diferencias son lo bastante grandes y líquidas como para ser operables. Para nosotros una señal sólo es una oportunidad real si cumple simultáneamente: (1) la relación evaluada es la correcta para opciones **americanas**, no la paridad europea; (2) la cotización estaba disponible en ese instante; (3) se compra al ask y se vende al bid, nunca al mid; (4) sobrevive comisiones, spread, *borrow* y latencia; (5) todas las patas tienen liquidez suficiente; (6) el resultado se sostiene fuera de muestra. Por eso separamos **detectores model-free**, que dependen sólo de relaciones de no arbitraje entre precios de mercado, de un **detector model-based**, que depende del precio del árbol binomial calibrado.

3. Activos subyacentes

La consigna asigna el ETF **ITA** como referencia del sector Defensa; como el ETF no es un subyacente válido, trabajamos con acciones individuales que pertenecen a su universo.

- **RTX — RTX Corporation.** Aeroespacial y defensa, opciones listadas líquidas, paga dividendos ($q > 0$ en el árbol).
- **BA — Boeing.** Aeroespacial, opciones listadas, sin dividendos desde 2020 ($q = 0$).
- **LMT — Lockheed Martin (agregado).** *Pure-play* de defensa con historia corporativa continua y opciones profundas. Lo elegimos en vez de GE Aerospace porque GE se escindió en tres compañías en abril de 2024 y su serie histórica previa no corresponde a la entidad actual (usarla violaría el control de *survivorship*/consistencia que nos propusimos respetar). LMT además aporta un régimen de volatilidad distinto: base baja, con saltos raros pero severos (cargos por programas de precio fijo), que complementa a BA (mayor volatilidad, colas gordas, sin dividendo) y a RTX (volatilidad media, la distribución más simétrica de los tres).

Cubrir tres regímenes de volatilidad es una decisión deliberada: un detector de arbitrajes validado contra un único régimen no está adecuadamente probado.

4. Revisión de literatura

Modelo binomial. Cox, Ross y Rubinstein [1] introducen el árbol binomial para valorar opciones: el subyacente evoluciona en pasos discretos hacia arriba o abajo y se descuenta el valor esperado bajo una probabilidad neutral al riesgo. Como RTX, BA y LMT tienen opciones **americanas**, el árbol nos permite comparar en cada nodo ejercer contra continuar — algo que un modelo cerrado europeo no captura.

Ejercicio anticipado. Barone-Adesi y Whaley [2] aproximan la valuación americana incorporando el ejercicio anticipado; Broadie y Detemple [3] comparan métodos de valuación americana. En nuestro proyecto, el árbol CRR es el modelo principal (calculamos `iv_american`) y Black-Scholes europeo queda como control (`iv_european`); la diferencia entre ambas cuantifica la prima de ejercicio anticipado. Reportar la IV europea sobre una put americana *in-the-money* y llamar “arbitraje” a la brecha resultante es justamente el error que quisimos evitar.

Superficie de volatilidad. La IV no es constante entre strikes y vencimientos: suele observarse *skew*, con puts OTM más caras por la demanda de protección. Una única sigma global puede producir supuestos arbitrajes en las alas cuando el problema real es la mala especificación del modelo; por eso dejamos el detector `model_dislocation` apagado por defecto en la operatoria en vivo.

Microestructura y ejecución. Una anomalía matemática no es operable si el spread, la latencia o la falta de profundidad consumen el edge. Con datos reales, entre el 40 % y el 58 % de las señales encoladas ya no existían en la apertura de la rueda siguiente (§11.1).

Significancia estadística. Bailey y López de Prado [4] formalizan el *Deflated Sharpe Ratio*: el Sharpe observado debe compararse contra el máximo que produciría, por azar, la búsqueda sobre N configuraciones sin poder predictivo. Adoptamos este criterio en vez de reportar sólo la configuración ganadora (§12).

Nuestra lectura aplicada es la siguiente: primero hay que comprobar relaciones *model-free* con precios ejecutables; recién después puede usarse el árbol binomial para detectar dislocaciones adicionales, siempre interpretadas junto con el smile, la liquidez y la incertidumbre de los parámetros. Una inconsistencia matemática no es, por sí sola, una oportunidad operable.

5. Arquitectura del pipeline

El flujo de datos es: *Alpaca/Polygon* $\rightarrow$ *universo de contratos* $\rightarrow$ *snapshots/velas* $\rightarrow$ *limpieza* $\rightarrow$ *alineación temporal* $\rightarrow$ *DTE, mid, spread, IV* $\rightarrow$ *filtros de liquidez* $\rightarrow$ *Parquet* $\rightarrow$ *detectores de arbitraje* $\rightarrow$ *backtest event-driven* $\rightarrow$ *evaluación IS/OOS*.

El código tiene 12 módulos con dependencias acíclicas: `volatility`, `config`, `schemas` y `calibration` no dependen de nada; `arbitrage` depende sólo de `volatility`; `backtest` de `arbitrage`; `evaluation` de `backtest`. Así, detectores, árbol y calibración se pueden testear sin credenciales ni red.

Módulo	Función
config / schemas	Subyacentes, tasas, dividendos, feed, credenciales; columnas y tipos del dataset.
clients / ingest	Gateway asincrónico sobre Alpaca; contratos, snapshots, backfill de barras.
enrich /	Mid, spread, DTE, alineación; árbol CRR, BSM, cotas de no arbitraje,
volatility	inversión de IV.
filters /	Filtros de liquidez auditables; Parquet particionado y manifiesto.
storage	
arbitrage	Seis detectores y edge neto.
backtest /	Motor event-driven, costos, kill-switch; split IS/OOS y Sharpe deflactado.
evaluation	
daily	Modo diario: sellado al cierre, curación sobre velas de Polygon.
execution/	Paper trading: órdenes multi-pata, riesgo previo, broker, ledger, secuencia de paridad.
pipeline	CLI: demo, doctor, record, backfill, enrich-daily, backtest-daily, paper-run.

6. Obtención de datos

6.1. Limitación estructural de Alpaca

Alpaca no expone cotizaciones históricas (NBBO) de opciones: el endpoint de cadena es un snapshot vivo, sin parámetro de fecha. Por eso el proyecto graba su propia serie hacia adelante (record, snapshots cada N segundos) y usa backfill para barras OHLCV pasadas con spread estimado (marcado `spread_is_proxy=True`). El feed gratuito (indicative) está demorado 15 minutos; el feed en tiempo real (opra) requiere suscripción paga. Un arbitraje detectado sobre un feed demorado no es explotable, y lo dejamos declarado explícitamente.

6.2. Fuente de la evidencia empírica: Polygon (modo diario)

Como Alpaca no permite reconstruir historia de opciones, **toda la evidencia empírica de este informe** (calibración, detección, backtest) sale de **Polygon (Massive)**, **plan gratuito**: no trae cotizaciones históricas de opciones, sólo velas diarias OHLCV+VWAP reales, con un límite de 5 requests por minuto. `scripts/download_polygon.py` descarga un request por contrato, acotando el universo antes de pedir datos: los dos vencimientos mensuales más próximos, y los cuatro strikes más cercanos por encima/debajo dentro de $\pm 15\%$ del spot de la rueda anterior.

Parámetro	Valor
Período	2026-03-01 a 2026-09-12 (134 ruedas)
Subyacentes / contratos	RTX, BA, LMT / 365
Velas diarias de opciones (reales)	7.323 (BA 3.121, RTX 2.425, LMT 1.777)
Requests / tiempo	415, en ~ 83 minutos

Vale la pena remarcarlo: estas 7.323 velas diarias son datos históricos **reales** de mercado descargados directamente de Polygon, rueda por rueda, y no una serie sintética ni simulada. Lo único sintetizado es el bid/ask (ver curación abajo), porque el plan gratuito no incluye NBBO histórico de opciones.

Curación (enrich-daily): cada vela se sella a las 16:00 ET de su rueda; el bid/ask se **sintetiza** alrededor de `close` o `vwap` con spread relativo s : $h = \max(ps/2, 0.01)$, $bid = p - h$, $ask = p + h$ (misma regla sobre `open` para la apertura de ejecución); todas esas filas quedan marcadas `spread_is_proxy=True`. Sin OI histórico, la liquidez se filtra por volumen de la rueda anterior.

7. Limpieza, alineación y control de calidad

- **Mid y precios ejecutables.** $m = (bid + ask)/2$ se usa para **calibrar**; para **simular una operación** siempre se compra al ask y se vende al bid.
- **Anti-lookahead.** Alpaca etiqueta barras por su apertura: la barra 14:30 recién se conoce completa a las 14:31. `align_underlying()` hace `merge_asof` contra `available_at = timestamp + duración, backward`, con tolerancia máxima. El subyacente se pide `adjustment=raw` (precios ajustados incorporarían información futura).
- **Open interest.** Se exige `open_interest_date < trade_date`; si no estaba disponible, se anula.
- **Survivorship.** El maestro append-only diario reconstruye qué contratos existían en cada fecha; los períodos anteriores al inicio de la grabación arrastran el sesgo, y así lo declaramos.
- **Data snooping.** El manifiesto versiona umbrales y supuestos junto al dataset.
- **Validación técnica.** La suite cubre convergencia del CRR al europeo sin dividendos, paridad put-call europea a 10^{-8} , prima de ejercicio anticipado no negativa, *round-trip* de IV a 10^{-9} , alineación contra una barra “envenenada”, y contratos reconstruidos del SDK real de Alpaca.

8. Modelo binomial CRR y calibración de la volatilidad implícita

El árbol CRR usa

$$u = e^{\sigma\sqrt{\Delta t}}, \quad d = \frac{1}{u}, \quad p = \frac{e^{(r-q)\Delta t} - d}{u - d},$$

y en cada nodo, con posibilidad de ejercicio anticipado,

$$V_i^n = \max \left(\text{payoff}_{i,n}, e^{-r\Delta t} [p V_{i+1}^{n+1} + (1-p) V_i^{n+1}] \right).$$

Obtenemos la IV resolviendo $V_{CRR}(\sigma) - V_{\text{mercado}} = 0$ con el método de **Brent** (no Newton-Raphson: el vega $\mathcal{V} = Se^{-q\tau}\phi(d_1)\sqrt{\tau}$ se anula en las colas, donde Newton diverge justo en los contratos *deep OTM* más interesantes). Antes de invertir controlamos la cota $\max(Se^{-q\tau} - Ke^{-r\tau}, S - K, 0) \leq C \leq S$: fuera de esa banda el solver devuelve NaN y marca `violates_bounds=True` en vez de forzar una raíz inexistente. Calculamos dos IVs por contrato: `iv_american` (la correcta) e `iv_european` (control).

Sobre los datos reales de Polygon, la IV americana se invirtió en **6.785 de 7.323** filas con cierre (mediana 33,4%) y 6.697 con VWAP (mediana 33,5%), con tasa plana y dividendos continuos. Esto sirve como control de consistencia (el solver converge, las cotas se respetan); todavía nos falta tabular formalmente el ajuste a la superficie observada (IV vs. *moneyness*, IV vs. vencimiento, RMSE ponderado por vega).

9. Detección de arbitrajes

Usamos cinco detectores **model-free** y uno **model-based**, todos sobre bid/ask (nunca mid), con edge neto en USD después de comisiones y liquidez de la peor pata:

Detector	Relación testeada
<code>monotonicity</code>	$K_1 < K_2 \Rightarrow C(K_1) \geq C(K_2)$
<code>vertical_bound</code>	$C(K_1) - C(K_2) \leq K_2 - K_1$
<code>butterfly</code>	$C(K_2) \leq w C(K_1) + (1-w) C(K_3)$ (convexidad)
<code>put_call_parity</code>	$Se^{-q\tau} - K \leq C_A - P_A \leq S - Ke^{-r\tau}$ (banda americana)
<code>calendar</code>	$T_2 > T_1 \Rightarrow C(T_2, K) \geq C(T_1, K)$
<code>model_dislocation</code>	Precio CRR contra el lado de mercado (model-based)

Un hallazgo importante surgió al correr los tests unitarios (`tests/test_arbitrage.py`): al reproducir las celdas 39–42 del notebook de cátedra sobre una cadena de precios sin arbitraje conocida de antemano, encontramos errores de signo. La mariposa daba 8/8 falsos positivos (signo invertido:

compra el cuerpo y vende las alas, payoff no positivo) y el calendario daba 10/10 (patas invertidas, en realidad detecta el spread normal); además, los “mejores arbitrajes” del output de cátedra tenían ask=0,00, es decir, una cotización ausente, no una call gratis. Corregimos las tres cosas en `arbitrage.py`, y el detector corregido pasa el mismo test con cero falsos positivos.

10. Filtros de liquidez

Los filtros no borran filas en silencio: marcan la causa en una columna `excl_*` y devuelven un reporte auditable.

Criterio	Umbral	Razón
Volumen	> 0	Sin volumen no hay evidencia de operabilidad.
Open interest	> 50	Sobre OI rezagado un día.
Bid	> 0	Bid cero colapsa el mid al medio ask: falsos arbitrajes.
Spread relativo	$< 15\%$	Es el costo de cruzar.
Mid	$\geq \text{USD } 0,05$	Bajo eso el tick de 1 centavo domina la señal.
DTE	7 a 180 días	<i>Pin risk</i> abajo, quotes poco confiables arriba.

Con los umbrales del modo diario (sin spread ni OI observado, sólo volumen de la rueda anterior) conservamos **5.602 de 7.323 filas (76,5 %)**: 1.008 quedaron excluidas por DTE fuera de rango, 788 por no tener volumen en la rueda anterior, y 230 (cierre) / 182 (VWAP) por precio menor a USD 0,05. Reportamos cada oportunidad con la liquidez de la **peor pata**.

11. Backtest: metodología y costos

El motor es **event-driven**: la señal ocurre en t_d y la ejecución en $t_e = t_d + \ell$; al ejecutar se **vuelven a cotizar todas las patas** y, si el crédito se evaporó, la operación se rechaza (**control de edge residual**). Los supuestos son: comisión USD 0,65/contrato, multiplicador 100, edge mínimo USD 5, *borrow* anual 0,50 % en cortos, spread de USD 0,01 en la acción, límite de posiciones simultáneas y tamaño por señal, kill-switch por posición. La barrera `PointInTimeView` levanta `LookaheadError` ante cualquier consulta hacia adelante: el control de lookahead es estructural, no una convención de código.

11.1. Resultados con datos reales

Diseño. Señal al cierre de t (16:00 ET); ejecución a la apertura (09:30 ET) de $t+1$ o $t+2$, sólo si el edge recalculado sigue $\geq \text{USD } 5$; hasta 20 posiciones simultáneas y 3 señales nuevas por rueda; salida por vencimiento (valor intrínseco), kill-switch, o fin de datos. Corrimos una grilla factorial $2 \times 2 \times 2 \times 2$: fuente de precio (`close/vwap`) $\times$ spread (2 %/5 %) $\times$ latencia ($t+1/t+2$) $\times$ kill-switch (USD 1.500/2.000). Fijamos la base *antes* de correr la grilla: cierre, 2 %, $t+1$, USD 2.000.

Configuración	Ops	P&L (USD)	Hit rate	Sharpe	DSR $N=16$
close · 2 % · t+1 · 1.500	92	16.311	96,7 %	1,56	0,71
close · 2 % · t+1 · 2.000 (base)	92	19.055	97,8 %	1,69	0,75
close · 2 % · t+2 · 1.500/2.000	88	20.030	97,7 %	1,79	0,77
close · 5 % · t+1 · 1.500	76	15.342	97,4 %	1,28	0,64
close · 5 % · t+1 · 2.000	76	19.005	98,7 %	1,50	0,70
close · 5 % · t+2 · 1.500/2.000	52	13.095	98,1 %	1,48	0,70
vwap · 2 % · t+1 · 1.500	102	11.667	93,1 %	0,68	0,47
vwap · 2 % · t+1 · 2.000	103	18.186	96,1 %	0,96	0,55
vwap · 2 % · t+2 · 1.500/2.000	89	16.048	98,9 %	1,21	0,62
vwap · 5 % · t+1 · 1.500	84	5.450	92,9 %	0,37	0,39
vwap · 5 % · t+1 · 2.000	84	10.522	94,0 %	0,69	0,47
vwap · 5 % · t+2 · 1.500/2.000	82	10.745	96,3 %	0,89	0,53

(Las filas con kill-switch 1.500/2.000 son idénticas en $t+2$: ese umbral nunca se activa con esa latencia. La tabla completa de 16 filas y el DSR con $N = 35$ están en `reportes_final/summary.csv`; el máximo drawdown va de USD 5.213 a 15.525, y es más alto con VWAP.)

Embudo (configuración base). De 2.537 violaciones detectadas, 397 entraron por el tope de señales por rueda, y de éstas: 92 se ejecutaron, 179 llegaron a la apertura con el edge ya desaparecido, 82 no tuvieron precio (el contrato no operó), 41 se quedaron sin capacidad, y 3 quedaron pendientes al cierre de los datos. Entre el 40 % y el 58 % de las señales encoladas de cada configuración se descartaron por edge desaparecido: es la evidencia empírica de que la latencia consume el edge teórico.

Detector	Detect.	Encol.	Ejec.	Edge desap.	Sin precio	Sin cap.
butterfly	1.235	112	20	58	25	8
put_call_parity	981	245	67	102	44	30
vertical_bound	210	29	4	12	11	2
monotonicity	103	11	1	7	2	1
calendar	8	0	0	0	0	0

Detector	Ops	P&L total	Hit rate	Edge capt.
put_call_parity	67	USD 16.534	99 %	1,20
butterfly	20	USD 1.740	95 %	0,58
vertical_bound	4	USD 749	100 %	2,39
monotonicity	1	USD 31	100 %	0,15
Por salida: expiry	81	USD 20.779	100 %	1,32
end_of_data	10	USD 851	90 %	1,09
stop_loss	1	−USD 2.575	0 %	−3,45

Vencimiento vs. kill-switch. En las 16 configuraciones, el **100 % de las operaciones liquidadas al vencimiento cerró con ganancia**: es la firma de estructuras de no arbitraje bien armadas. El kill-switch (que pensamos como red de contención, no como toma de ganancias) se activó entre 0 y 5 veces por configuración, siempre con pérdida; en la base, se activó una vez, en una paridad de LMT que atravesó su fecha ex-dividendo del 1 de junio (−USD 2.575), justo el caso donde el supuesto de dividendo continuo desplaza la cota de la paridad.

Fondeo y dividendos no contabilizados. El P&L simulado de la paridad supera el edge al ejecutar (captura 1,20 en la base): el backtest no cobra intereses sobre el nocional de la acción ni los dividendos durante la tenencia. Estimando con tasa plana de 4,25 % y dividendos reales de Polygon, el P&L ajustado de la base baja de **USD 19.055 a USD 17.243** (−USD 922 de fondeo, −USD 889 de dividendos); en el resto de la grilla el ajuste va de −USD 795 a −USD 2.891, y el P&L ajustado estimado queda entre USD 4.345 y 18.131 según configuración (siempre positivo, pero consistentemente menor al simulado).

En resumen: (1) el signo es positivo en las 16 configuraciones; (2) la paridad concentra el resultado y también los supuestos no contabilizados; (3) VWAP no mejora — Sharpe más bajo, drawdown

casi el doble, más señales falsas por comparar el VWAP de la opción con el cierre de la acción; (4) a más spread supuesto, menos oportunidades; (5) la latencia no tiene un efecto monótono; (6) ninguna configuración supera un DSR de 0,95.

12. In-sample / out-of-sample y significancia estadística

`evaluation.py` soporta split cronológico (60/40 por defecto) y grid search sobre edge mínimo, spread máximo, OI/volumen mínimos, DTE máximo, posiciones, detectores activos, latencia, stop-loss y tamaño; la grilla registra **todas** las configuraciones, no sólo la ganadora.

El *Deflated Sharpe Ratio* [4] compara el Sharpe observado contra el máximo esperable por azar al probar N configuraciones sin poder predictivo:

$$\mathbb{E}[\widehat{SR}] \approx \sqrt{V} \left[(1 - \gamma) \Phi^{-1} \left(1 - \frac{1}{N} \right) + \gamma \Phi^{-1} \left(1 - \frac{1}{Ne} \right) \right],$$

con V la varianza de los Sharpe entre configuraciones (0,00074 por rueda) y γ la constante de Euler-Mascheroni; luego corregimos por asimetría y curtosis de los retornos. Un $DSR < 0,95$ indica que el resultado no se distingue de una búsqueda sobre ruido.

Declaración de la búsqueda previa. Antes de la grilla de 16 hubo tres corridas sin control de edge residual y una grilla de 16 con stop-loss de USD 500 o desactivado; decidimos la ejecución a la apertura y los niveles del kill-switch *después* de ver esos resultados. Por eso reportamos el DSR con $N = 16$ (grilla definitiva) y con $N = 35$ (las 35 configuraciones evaluadas en total, el valor más honesto): DSR base 0,75/0,71; mejor configuración (cierre·2%·t+2) 0,77/0,74; peor (VWAP·5%·t+1·1.500) 0,39/0,35. **Ninguna alcanza 0,95:** con 134 ruedas, un Sharpe anualizado de 1,69 no alcanza para distinguir la estrategia de un máximo producido por la búsqueda de hiperparámetros. Todavía nos falta aplicar el split temporal in-sample/out-of-sample propiamente dicho, que con sólo seis meses de historia mensual deja muy pocos vencimientos por tramo; lo haremos cuando tengamos al menos un año de datos.

13. Ejecución: paper trading

La ejecución está en fase de **piloto**: está implementada y testeada contra un *broker falso* que reproduce fills parciales y rechazos observados en paper, y ya tuvimos las primeras corridas contra la cuenta paper real de Alpaca. `doctor` valida credenciales, nivel de opciones, *buying power*, short habilitado y reloj de mercado antes de operar. `paper-run` corre un ciclo cada 90 segundos: snapshots del universo chico, detección de monotonicidad/spread vertical/mariposas/paridad, deduplicación, controles de riesgo previos (pérdida máxima, profundidad, fecha ex-dividendo, short), enrutamiento (orden *multi-leg* para opciones, secuencia de patas separada para la paridad), gestión de riesgo (kill-switch, límite diario, cierre antes del vencimiento, archivo KILL de corte manual) y reconciliación del ledger SQLite contra Alpaca en cada ciclo.

Hallazgo del dry-run (14-09-2026). Alpaca rechazó (código 40310000) una orden `mleg` que vendía el call mientras la compra de acciones seguía `partially_filled`. Corregimos secuenciando la ejecución: acciones con límite marcabable → fill completo o cancelación → posición confirmada → edge residual recalculado con el precio real → recién entonces la `mleg` de opciones; si se rechaza, se deshacen las acciones. El cierre invierte el orden. Después agregamos: spot alineado a la barra IEX de 1 minuto vigente (no el último quote, que con opciones demoradas fabricaba reversas de paridad espurias); signo de posición tomado del campo `side` de Alpaca; excepciones que no matan el loop (se registran, se detienen entradas nuevas, se siguen gestionando posiciones); diagnóstico por ciclo en `cycles.csv`.

Límites del piloto. Con feed `indicative` validamos la **cañería** (órdenes, estados, reconciliación, kill-switch), no el edge en tiempo real. El paper de Alpaca no simula *slippage*, dividendos ni costo de préstamo, y ejercicios/asignaciones se sincronizan al día siguiente. **Todavía no probamos** el loop completo durante una rueda entera contra la API real; es el paso previo a operar con tamaños de validación.

14. Monitoreo y stop-loss

Hoy el stop-loss funciona como **kill-switch de cola** dentro del backtest y del piloto: cierra una posición cuando la pérdida no realizada supera un umbral. Un umbral estrecho (USD 500) resultó incompatible con estrategias de convergencia marcadas con cierres asincrónicos — el ruido del mercado disparaba el stop y cristalizaba pérdidas en posiciones que al vencimiento habrían convergido — por eso lo fijamos en USD 1.500–2.000 (4-5 % del nocional medio de una conversión), decisión que tomamos después de observar el resultado con USD 500 (y que queda declarada en el DSR con $N = 35$, §12). El sistema de monitoreo productivo (P&L realizado/no realizado, drawdown, exposición por subyacente y vencimiento, edge capturado, quotes *stale*, errores de API, con stop-loss por posición y diario, límite de exposición, cierre por pata faltante o pérdida de conexión) ya está especificado pero **todavía no desplegado como proceso continuo**; el ledger con reconciliación por ciclo es la base sobre la que lo vamos a construir.

15. Resultados finales y conclusiones

1. El binomial americano es más apropiado que Black-Scholes europeo: incorpora ejercicio anticipado, relevante en RTX y LMT (dividendos).
2. Las relaciones **model-free** son la evidencia más fuerte porque no dependen de una sigma bien calibrada.
3. Bid-ask, latencia y liquidez pueden eliminar el edge teórico: entre 40 % y 58 % de las señales encoladas ya no existían en la apertura.
4. El control temporal de los datos es tan importante como la fórmula de valuación: sin verificar el edge residual, el backtest medía señales vencidas.
5. La ausencia de NBBO histórico nos obliga a suponer bid/ask con el plan gratuito de Polygon.
6. Con datos reales y edge residual verificado, las 16 configuraciones dan P&L positivo y el 100 % de lo liquidado al vencimiento gana.
7. Un stop-loss estrecho es incompatible con estrategias de convergencia marcadas con precios asincrónicos; el kill-switch debe calibrarse como red de cola.
8. La paridad put-call aporta $\sim 87\%$ del P&L y es la más afectada por costos no contabilizados (fondeo y dividendos): USD 19.055 $\rightarrow$ 17.243 en la base.
9. **Ninguna configuración alcanza un DSR de 0,95**: la evidencia todavía no alcanza para afirmar rentabilidad fuera de muestra.
10. Antes de un P&L real nos falta contabilizar fondeo/dividendos, grabar cotizaciones propias, completar el paper trading y desplegar el monitoreo.

Conclusión general. Una inconsistencia matemática no es automáticamente una oportunidad de trading. Para ser explotable necesita una cotización ejecutable, liquidez en todas las patas, la relación financiera correcta para opciones americanas, costos y latencia compatibles, y un resultado que sobreviva fuera de muestra.

16. Limitaciones

Del backtest: sin costo de fondeo ni dividendos discretos en conversiones; dividendos modelados como yield continuo (RTX y LMT los pagan en fechas discretas); cierres asincrónicos entre contratos; VWAP de la opción incoherente con el cierre del spot; bid/ask sintéticos (2 % o 5 % supuesto); sin profundidad ni OI histórico; tope de 20 posiciones que rechaza señales; sin modelar asignación anticipada; universo acotado a strikes listados al inicio de la ventana.

Generales: sin NBBO histórico completo en Alpaca; feed gratuito demorado 15 min; spread proxy en barras de backfill; sigma global no representa todo el smile; una misma dislocación puede duplicar oportunidades; el *recorder* no refresca el maestro si queda corriendo varios días; *enrich* usa sólo el último maestro de OI (se anula en fechas pasadas); la CLI usa RTX/BA por defecto, LMT requiere *-tickers*; la historia previa al *recorder* arrastra *survivorship bias*; el detector de mariposas

es $O(n^3)$ (130 de 145 s sobre 945 contratos sin `consecutive_only=True`); la ejecución paper y el monitoreo siguen en fase de piloto, no de operación continua validada.

17. Estado consolidado

Etapa	Estado al 14-09-2026
Literatura	Revisada e incorporada (§4).
Datos	Polygon: 365 contratos, 7.323 velas diarias reales. Alpaca (record/backfill) implementado, sin historia propia acumulada aún.
Limpieza y calidad	Implementada, testeada, aplicada sobre datos reales.
Calibración binomial	Implementada, testeada; IV real invertida en 6.785/7.323 filas. Falta la tabla de ajuste a la superficie observada.
Detección de arbitrajes	Implementada, corregida contra falsos positivos de cátedra, aplicada sobre datos reales.
Backtest realista	Costos, ejecución a la apertura, edge residual, kill-switch, anti-lookahead; grilla de 16 sobre datos reales.
IS/OOS	DSR calculado ($N=16$, $N=35$); falta split cronológico con >1 año de historia.
Paper trading	Piloto con broker falso y primeras corridas reales; secuencia de paridad corregida. Falta correr una rueda completa antes de validar tamaños.
Monitoreo/stop-loss	Kill-switch activo en backtest y piloto; monitor continuo productivo pendiente.
P&L real	No disponible todavía: lo reportado es simulado (backtest) o de piloto sin capital en escala.

Para la Parte 2, este documento es la base: las estrategias deben seguir en producción, Black-Scholes competirá contra el binomial ya calibrado sobre RTX/BA/LMT, y vamos a reportar el P&L acumulado de ambas partes.

Referencias

- [1] Cox, J. C., Ross, S. A., & Rubinstein, M. (1979). *Option Pricing: A Simplified Approach*. Journal of Financial Economics, 7(3), 229–263.
- [2] Barone-Adesi, G., & Whaley, R. E. (1987). *Efficient Analytic Approximation of American Option Values*. Journal of Finance, 42(2), 301–320.
- [3] Broadie, M., & Detemple, J. (1996). *American Option Valuation: New Bounds, Approximations, and a Comparison of Existing Methods*. Review of Financial Studies, 9(4), 1211–1250.
- [4] Bailey, D. H., & López de Prado, M. (2014). *The Deflated Sharpe Ratio: Correcting for Selection Bias, Backtest Overfitting, and Non-Normality*. Journal of Portfolio Management, 40(5), 94–107.